

Západočeská univerzita v Plzni
Fakulta aplikovaných věd
Katedra informatiky a výpočetní techniky

Diplomová práce

Datový model EEG/ERP portálu v prostředcích sémantického webu

Prohlášení

Prohlašuji, že jsem diplomovou práci vypracoval samostatně a výhradně s použitím citovaných pramenů.

V Plzni dne 18. dubna 2013

Filip Markvart

Abstract

This thesis DODELAT

Obsah

1	Úvod	1
2	Sémantický web	2
2.1	Architektura sémantického webu	4
2.2	XML	5
2.3	RDF	6
2.4	RDFS	8
2.4.1	Třídy	8
2.4.2	Vlastnosti	9
2.5	Ontologie	11
2.6	OWL	12
2.7	SPARQL	13
3	EEG/ERP portál	16
3.1	Technologie portálu	16
3.2	Persistentní data	17
4	Relační datový model	19
4.1	Limity relační databáze	21
4.1.1	Dědičnost	21
4.1.2	Vztahy mezi relacemi	21
4.2	Datový model EEG/ERP portálu	22
5	Datový model sémantického webu	25
5.1	Dynamičnost modelu	26
5.2	Dědičnost a hierarchie dat	26
5.3	Problémy modelu	27
5.4	Porovnání modelů	27
6	Nástroje pro vývoj sémantického webu	29
6.1	Virtuoso	29

6.2	Oracle 11g - Oracle Spatial	30
6.3	Jena	31
7	Transformace datového modelu	33
7.1	Rozdělení datového modelu	33
7.2	Relační část modelu	34
7.3	Sémantická část	35
7.3.1	Transformace tabulek	35
7.3.2	Transformace rozkladových tabulek	36
7.3.3	Transformace atributů tabulek	37
7.3.4	Transformace datových typů	38
7.3.5	Transformace záznamů tabulek	39
7.3.6	Dodání sémantiky modelu	39
7.3.7	Řešení rozšiřujících tabulek	40
7.3.8	Ukázka transformace	40
7.3.9	Výhody navrženého modelu	41
7.3.10	Nevýhody navrženého modelu	41
8	Testování řešení	42
9	Závěr	43

1 Úvod

EEG/ERP portál je webová aplikace sloužící výzkumným pracovníkům ke shromažďování a organizaci dat získaných při neuroinformatických experimentech v EEG laboratoři. Jejím cílem je ukládání naměřených dat v kontextu prováděného experimentu, který lze popsat rozsáhlou množinou různorodých údajů. Tato aplikace již prošla mnohaletým vývojem v jehož průběhu postupně docházelo ke změnám datového modelu kvůli přibývajícím požadavkům na uchovávaná data. Relační databáze jež slouží jako persistentní úložiště tak postupně byla rozšiřována o další tabulky, jejichž počet se k datu tvorby této práce pohybuje v řádu desítek. Většina realizací požadavků na ukládání dalších dat tak přímo znamená zásah nejen do databáze portálu ale také to do datové vrstvy, která ji využívá. V současné době tak databáze obsahuje velké množství tabulek uchovávající různá data, která jsou ale ve smyslu sémantiky často příbuzná a existuje mezi nimi vazba, která je prostřednictvím relačního datového modelu velmi obtížně popsatelná. Zároveň lze očekávat, že budou přibývat požadavky na uchování dalších dat, která navíc nemusejí mít jen homogenní strukturu (ve smyslu relační databáze), ale může se jednat i o množiny sémanticky příbuzných údajů – tzv. metadata, které budou vázány pouze k některým datům. Možnost ukládání strukturně heterogenních, ale sémantický příbuzných metadat je tak dalším otevřeným problémem.

Cílem této práce je prozkoumání struktury a nalezení sémantiky dat v současném datovém modelu relační databáze portálu a následná úprava tohoto modelu do podoby, která by dovolovala uchovat jak sémantiku dat, kterou není možné relačním modelem vyjádřit tak dodávat dynamicky datům přídatná metadata, aniž by muselo docházet k větším zásahům do datového modelu portálu. Pro realizaci úpravy datového modelu budou v této práci využity prostředky tzv. sémantického webu, který poskytuje množství standardů a technologií pro uchovávaní organizaci a správu dat. Tyto technologie a nástroje zde budou popsány a na základě jejich analýzy budou vybrány prostředky, které se využijí pro implementaci úpravy zmiňovaného datového modelu. Poslední část práce se věnuje testování modifikovaného modelu a to především z výkonnostního hlediska. Díky této části by mělo být možné posoudit jak užitečnost samotné úpravy tak i použitelnost a efektivnost získaného modelu pro potřeby EEG/ERP portálu.

2 Sémantický web

Dnešní podoba webu, tak jak je všeobecně známa, je tvořena značným množstvím informací, které mají řadu autorů, v podobě různých organizací či jednotlivců, jež se liší jak svým obsahem tak i podobou publikace. Tyto informace jsou poměrně snadno přístupné díky jejich jednoznačné identifikaci prostřednictvím URI identifikátoru (za předpokladu, že jej známe). K usnadnění získávání dalších (často příbuzných) informací napomáhají tzv. hypertextové odkazy, jež usnadňují přístup k dalším zdrojům informací odstraněním požadavku na uživatelskou znalost identifikátoru cílového zdroje. Samotné hypertextové odkazy tak sice zajišťují provázání jednoho informačního zdroje s jiným díky znalosti jeho URI identifikátoru, ale nenesou už žádné další informace, které by například uživateli poskytly další údaje o cílovém zdroji. Takováto podoba umožňuje získávání informací jak koncovým uživatelům webu, tak v omezené podobě i vyhledávacím strojům, ale má své limity, neboť se v nepřehledném množství dat lze snadno ztratit, či se jen dostat k irelevantním informacím [27]. Základním úkolem sémantického webu, jehož první myšlenky prezentoval v roce 2001 zakladatel konsorcia W3C Tim Berners-Lee, je umožnit aby informace dostupné prostřednictvím webu byly srozumitelné nejen uživatelům, ale také počítačům, jež tato data zpracovávají [21]. Hlavním cílem je tedy vývoj standardů a technologií, které by umožňovaly přesnější a podrobnější vyhledávání, integraci dat a také automatizaci častých úkonů. Sémantický web je založen na několika principech, které budou níže uvedeny.

- **Jednoznačná identifikace entit prostřednictvím URI**

Veškerá data, reprezentující obvykle objekty reálného světa publikovaná prostřednictvím webu je možné jednoznačně odkazovat prostřednictvím identifikátoru URI. Díky této skutečnosti je tak možné realizovat i nepřímé odkazy na objekty, například osobu Petr Novák s emailem petr.novak@w3.org je možné identifikovat jako osobou, jejíž email má URI mailto:petr.novak@w3.org.

- **Zdroje i odkazy mezi nimi je možné typovat**

Současná podoba webu je tvořena zdroji a odkazy jež je vzájemně propojují. Zdroje, které jsou reprezentovány webovými dokumenty jsou publikovány za účelem poskytnutí informací lidskému uživateli, který dokáže ze samotného obsahu dokumentu získat i některá jeho metadata

(pokud jsou v určité formě součástí obsahu) a do jisté míry pak také vztah k ostatním dokumentům, na něž vedou případné odkazy. Stroje v podobě různých vyhledávačů či automatů pro shromažďování dat ale tuto schopnost nemají nebo je pro ně příliš náročná. Řešením sémantického webu je typování jak samotných zdrojů, tak i odkazů, které je provazují. Díky této skutečnosti je pak možné webovým dokumentům dodávat metadata jako např. autora, verzi či závislost na jiném dokumentu. Z hlediska typování odkazů je například možné jeden webový zdroj označit pouze jako odlišnou verzi jiného zdroje.

- **Tolerance neúplných informací**

U současně podoby webu může nastat situace, kdy některý zdroj není dostupný. V takovém případě uživatel ztrácí přístup k danému dokumentu, ale díky koncepci webu není nikterak ohrožena dostupnost ostatních zdrojů. V případě sémantického webu se situace nemění, nedostupnost některého zdroje není žádnou překážkou, neboť nástroje sémantického webu zpracovávají pouze ty informace, které jsou dostupné a z těch vytvářejí závěry. V důsledku je tak možné dojít při zpracovávání dat ke stejným výsledkům, jako v případě, když jsou zpracovávány jen některé vybrané informace, jejichž rozsah je explicitně definován.

- **Zpracování neověřených dat**

Při zpracovávání informací pocházejících z neověřených zdrojů je možné dohledávat prostřednictvím typovaných odkazů důvěryhodná data, jejichž obsah a odkazy poslouží jako ověřovací prostředek. Tento princip je možné uvést na následujícím příkladu. Aplikace zpracovávající data sémantického webu vyhledá informace, přičemž je kladen požadavek na vysokou pravděpodobnost správnosti výsledku. Pokud některá část nalezených informací pochází z neověřeného zdroje, je možné vyhledávat například jejich autora v odkazech zdrojů, které jsou důvěryhodné či ověřené. V případě úspěchu nalezení takového odkazu u více různých zdrojů je pak možné považovat zkoumaný zdroj s vysokou pravděpodobností rovněž za důvěryhodný a tím zajistit plnění požadavků na výsledek.

- **Podpora paralelního vývoje dat**


V průběhu času neznámá nastávají situace, kdy autoři, či skupiny autorů publikují obdobná data na různých místech nebo v odlišném čase. Obsah těchto dokumentů se může navíc lišit svým jazykem či použitou terminologií, ač význam bude shodný. S využitím prostředků sémantického webu je ale možné prostřednictvím typovaných odkazů zajistit provázanost významově obdobných či na sebe navazujících dat

i přes překážku rozdílnosti jejich podoby zápisu. Navíc je také možné dodávat nové informace bez nutnosti úpravy původních dat, která tím pádem nezmění svoji strukturu [27].

2.1 Architektura sémantického webu

Architektura sémantického webu sestává z více oddělených vrstev, mezi nimiž je zajištěna zpětná i dopředná kompatibilita [20]. Nejnižší vrstva je tvořena dvěma technologickými standardy – URI identifikátory sloužící pro jednoznačné pojmenování zdrojů dat a Unicode kódování mezinárodní znakovou sadou. Druhou vrstvu architektury, jež je patrná z obrázku 2.1, reprezentuje značkovací jazyk XML (Extensible Markup Language), který umožňuje tvorbu strukturovaného dokumentu za užití vlastních značek. Tato vrstva zároveň zajišťuje definici XML schématu včetně jmenných prostorů. RDF + rdfschema jež následuje je klíčovou vrstvou sémantického webu neboť dovoluje tvorbu vazeb a vztahů mezi jednotlivými zdroji, které jsou typované spolu s odkazy. Je tak možné definovat libovolné vztahy mezi objekty či jejich kategoriemi bez nutnosti specifikace významu samotných vazeb či objektů. Díky RDF schématu je vytvářena základní sémantika datového modelu, která už definuje význam některých elementů jako třídy či podtřídy. Vrstva ontologického slovníku, zastoupená jazykem OWL, nabízí pokročilou reprezentaci znalostí na úrovni deskripční logiky a umožňuje tak vytvářet složitější struktury sloužící k popisu různých vlastností objektů [21]. Poslední vrstvou, která je jako všechny předchozí zmíněné konsorciem W3C standardizovaná jsou digitální podpisy. Ty poskytují možnosti například pro detekci různých verzí dokumentů. Zbylé výše znázorněné vrstvy slouží pro definice a vyhodnocování odvozovacích pravidel a v současnosti jsou ve fázi vývoje [27].

Vrstvení jazyků sémantického webu je podstatné pro úroveň expresivity znalostního modelu, neboť s rostoucí vyjadřovací možností jazyka také roste složitost dotazovacích operací nad modelem. Je tedy nutné před započatím tvorby modelu nejprve zjistit jeho požadovanou expresivitu a podle té zvolit pro zápis dat jazyk, který ji dovoluje obsáhnout. Využívá se tedy skutečnosti, že jazyk vyšší vrstvy zahrnuje vyjadřovací schopnosti vrstev nižších [21]. Další podkapitoly se budou zabývat podrobněji jednotlivými zmíněnými technologiemi.



Obrázek 2.1: Architektura sémantickém webu [27]

2.2 XML

XML (eXtensible Markup Language) je značkovací jazyk sloužící pro popis hierarchických struktur textových dokumentů prostřednictvím tzv. tagů. Tag je konstrukce, která slouží k počátečnímu a koncovému ohrazení společně definovaného elementu. Tag lze chápat jako prostředek pro dodání metadat ke textové struktuře, jež ohraňuje. Příkladem může být následující zápis `<prijmeni>Novák</prijmeni>`, kde elementu *Novák* je dodána meta informace, že se jedná o příjmení. Samotné XML ale nedefinuje žádný sémantický význam tagů, slouží pouze pro specifikaci syntaxe na úrovni XML dokumentu. Pro definici (zejména hierarchické) struktury XML dokumentu slouží XML Schema, které umožňuje zápis pravidel, jež musí cílový dokument dodržovat pro zachování své validity. Ze strany sémantického webu ale nemají pravidla XML Schema žádný sémantický význam a slouží tak pouze pro definici struktury a syntaxe. Zmíněné schéma také definuje základní datové typy (čísla, řetězce, čas a pod.), které nabývají významu v sémantických jazycích jako je RDF [20].

2.3 RDF


Technologický základ sémantického webu tvoří jazyk RDF (Resource Description Framework), jež slouží jako obecný rámec pro popis, výměnu a opětovné použití metadat [20]. Tento rámec poskytuje jednoduchý model sloužící pro popis zdrojů jež je nezávislý na jeho konkrétní implementaci [10]. Samotné informace o objektu jsou realizovány prostřednictvím tvrzení, jež se označují jako trojice (anglicky triple). Každou trojici tvoří spolu subjekt, predikát a objekt. Subjekt je libovolný objekt identifikovatelný prostřednictvím URI, který se snažíme prostřednictvím trojice popisovat, zaznamenat nějakou jeho vlastnost. Tato vlastnost se popisuje prostřednictvím predikátu, který vede ve směru od subjektu ke objektu, přiřazuje tedy subjektu nějaký objekt prostřednictvím této vlastnosti. Cílový objekt pak představuje hodnotu, které předchozí objekt nabývá pro daný predikát. Tento princip je možné znázornit na jednoduchém tvrzení, zapsaném větou „Martin staví dům.“ Subjektem trojice potom bude Martin, predikátem staví a objektem dům, tak jak je znázorněno na obrázku 2.2.



Obrázek 2.2: Příklad RDF trojice

Dle definovaného standardu [25] je možné, aby objektem byl jiný subjekt. Díky této skutečnosti je možné jednotlivé trojice spojovat do většího celku, který ve výsledku tvoří strukturu orientovaného grafu, kterou lze označit jako model [20]. Jednoduchým model tvořený dvěma trojicemi lze vytvořit využitím dalšího tvrzení „Dům stojí v Plzni.“ V předchozí trojici pak bude dům subjektem namísto objektu a dojde tak ke spojení dvou trojic (za předpokladu že v obou tvrzeních je myšlen stejný fyzický dům), tak jak je znázorněno na obrázku 2.3.

Z hlediska implementace mohou být uzly orientovaného grafu datového modelu tvořeny URI identifikátorem, anonymním listem nebo literálem [23]. URI identifikátor obsahuje pouze adresu zdroje v textové podobě ve znakové sadě Unicode a zastupuje tak konkrétní jedinečný objekt. Anonymní list (anglicky blank node) je prvek nahrazující URI identifikátor při absenci unikátní adresy zdroje. Tato entita představuje zdroj, který je sice v rámci



Obrázek 2.3: Příklad jednoduchého RDF modelu

grafu popisován prostřednictvím trojic, ale není potřeba (často z hlediska významu), aby byl dostupný i vně grafu. S URI má společné to, že musí nést adresu zdroje (její syntaxe není implicitně definována), ale liší se skutečností, že tato adresa musí být unikátní pouze v rámci obalujícího modelu, nikoliv vně grafu. Může tak nastat situace, že dva odlišné modely budou obsahovat (ze syntaktického hlediska) dva stejné anonymní uzly, což v případě URI možné není (při respektování specifikace). Tento list tak může představovat anonymní objekt sloužící ke vytvoření vazby mezi jinými objekty, které jsou z hlediska sémantiky významné [25]. Jako příklad je možno uvést následující tvrzení. „Martinův přítel zná předpověď počasí. Počasí bude deštivé.” Zjednodušeným převodem předchozích vět na trojice v podobě subjekt – predikát – objekt získáme: *Martin* – *má* – *přítel*, *přítel* – *zná* – *počasí*, *počasí* – *bude* – *deštivé*. Subjekt resp. objekt přítel zde může být reprezentován anonymním listem, v případě že jedinou signifikantní informací (z vnějšího pohledu na datový model) je Martinova získaná znalost počasí, nikoliv už jeho přítel, jež mu ji zprostředkoval. Poslední možnou reprezentací entity trojice je literál, jež nese Unicode textový řetězec, který slouží pro zápis koncové informace (užitečné pro lidského čtenáře). Literál může také navíc obsahovat položku, pro označení jazyka, ve kterém je textová informace zapsána [23].

Pro komponenty každé trojice grafu platí následující pravidla [23].

- **subjekt** - může být tvořen URI identifikátorem nebo anonymním listem
- **predikát** - může být tvořen pouze URI identifikátorem
- **objekt** - může být tvořen URI, anonymním listem nebo literálem

Pro zápis trojic RDF grafu je sice možné využít grafické podoby, ale pro vyjádření sémantiky webových zdrojů je nejvhodnější využít syntaxe jazyka XML. Níže uvedená ukázka kódu reprezentuje XML zápis trojice z obrázku 2.2.

```
<rdf:RDF xmlns:rdf="http://www.w3.org/1999/02/22-rdf-syntax-ns#"
          xmlns:dc="http://purl.org/dc/elements/1.1/">
  <rdf:Description rdf:about="http://www.w3.org/Person/Martin">
    <dc:stavi>dům</dc:stavi>
  </rdf:Description>
</rdf:RDF>
```

Samotné RDF nedefinuje trojicím ani jejím částem sémantiku, ale dovoluje vyjádřit základní vztahy náležitosti prvků do kategorie prostřednictvím kontejnerů a kolekcí (např. `rdf:Bag`, `rdf:List`) [21]. Pro dodání základní sémantiky slouží schéma popsané v následující podkapitole.

2.4 RDFS

RDF Schema (Resource Description Framework Schema) funguje jako základní jazyk pro tvorbu ontologií s velmi jednoduchou sémantikou. Toto schéma rozšiřuje jazyk RDF o možnosti vyjádření vlastností objektů, konstrukce tříd objektů a popis jejich hierarchie [21]. Prostředky jazyka RDFS umožňují především vyjádření vztahů mezi zdroji, které lze rozdělit na dvě skupiny – třídy a vlastnosti.

2.4.1 Třídy

Skupiny zdrojů je možné rozčleňovat do skupin označovaných jako třídy (classes), jejichž členové se nazývají instance třídy. Na úrovni RDFS se rozlišují třídy od svých instancí a každá třída jich může mít neomezený počet. Dvě třídy mohou mít navíc shodnou množinu instancí tříd a zároveň tyto třídy mohou být navzájem různé. Bude-li se tedy například definovat třída *A* jako osoby pracující v kanceláři *1* a třída *B* jako osoby žijící ve městě *X*. Potom je možné aby různé třídy *A* a *B* měly stejné množiny instancí, za předpokladu,

že každá osoba pracující v kanceláři 1 bydlí ve městě X. Pro třídy platí také dědičnost – bude li třída *B* podtřídou *A*, pak všechny instance *B* jsou zároveň instancí třídy *A*. Koncept tříd RDFS definuje následující konstrukce [26]:

- **rdfs:Resource** představuje RDF zdroj, který je obalující třídou všech prvků – je tedy nejvýše postavenou rodičovskou třídou, *rdfs:Resource* je zároveň instancí *rdfs:Class*
- **rdfs:Class** reprezentuje rodičovskou třídu všech RDF tříd zdrojů, čímž je *rdfs:Class* instancí *rdfs:Class* (sebe sama)
- **rdfs:Literal** třída je instancí *rdfs:Class*, která slouží pro reprezentaci RDF literálů a je podtřídou *rdfs:Resource*
- **rdfs:Datatype** je obalující třídou pro datové typy, které jsou její instancí, *rdfs:Datatype* je zároveň podtřídou i instancí *rdfs:Class* a každá její instance je podtřídou *rdfs:Literal*
- **rdf:XMLLiteral** je třída XML literálů, která je podtřídou *rdfs:Literal* a instancí *rdfs:Datatype*
- **rdf:Property** představuje rodičovskou třídu všech definovaných vlastností a je instancí *rdfs:Class*

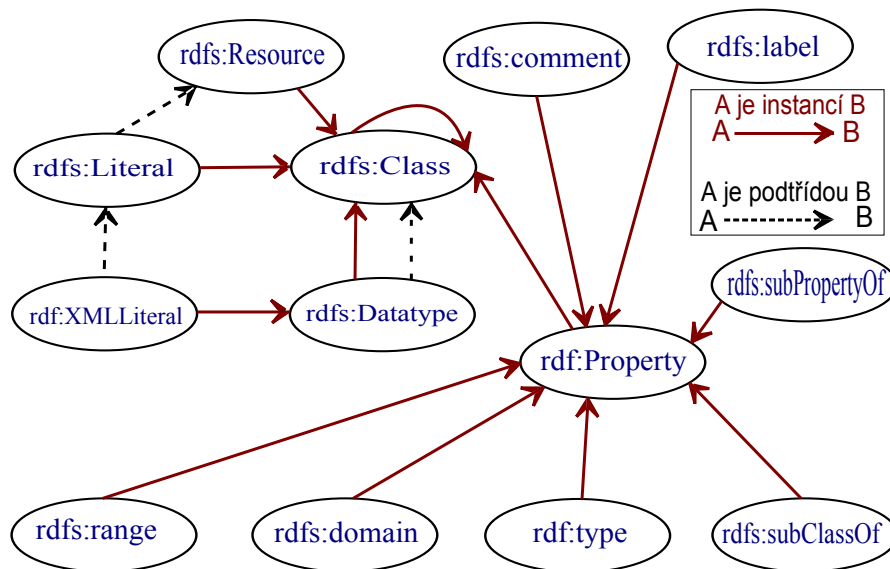
2.4.2 Vlastnosti

Vlastnosti (properties) slouží k vyjádření vztahu mezi dvěma zdroji – na úrovni trojice mezi subjektem a objektem. Koncept RDFS definuje následující vlastnosti:

- **rdfs:range** je instancí *rdf:Property*, která slouží ke vyjádření, že objekt jehož predikát má definovaný *rdfs:Range* *X* bude zároveň instancí *X*, například z následujících trojic *A – rdfs:Range B* a *X – A – C* bude vyplývat, že *C* je instancí *B*, zároveň platí, že objekt s definovaným predikátem může být instancí více tříd (pokud má predikát definováno více *rdfs:Range*).
- **rdfs:domain** představuje instanci *rdf:Property*, která vyjadřuje, že zdroj (subjekt) jehož predikát má definovaný *rdfs:Domain* *X* bude také instancí *X*, tento zdroj může být jako v předchozím případě instancí více tříd při definování více *rdfs:Domain*

- **rdf:type** slouží k definování, že zdroj (subjekt) je instancí třídy definované objektem, pokud tedy platí $A \text{ rdf:type } B$, pak A je instancí B
- **rdfs:subClassOf** je vlastnost sloužící k vyjádření náležitosti instancí jedné třídy jako instancí jiné třídy, pokud platí $A \text{ rdfs:subClassOf } B$, pak A je podtřídou B a všechny instance třídy A jsou zároveň instancí třídy B , tato vlastnost je navíc tranzitivní, takže popsanou dědičnost je možné řetězit do libovolné délky
- **rdfs:subPropertyOf** slouží k vyjádření dědičnosti vlastností, pokud platí $P1 \text{ subproperty } P2$, pak pro trojici $A \ P1 \ B$ platí, že subjekt A má pro vlastnost $P1$ i $P2$ pro objekt B
- **rdfs:label** umožňuje zdroji (subjektu) přidat textovou informaci jako lidsky čitelnou náhradu pro označení zdroje
- **rdfs:comment** dovoluje přidat zdroji popis, který usnadňuje lidskému uživateli pochopit význam zdroje [26]

Vyjádření vztahů mezi jednotlivými vlastnostmi a třídami je patrné z obrázku 2.4. Rámec RDFS dále ještě definuje vlastnosti a třídy pro kontejnery a kolekce, které je možné nalézt ve [26].



Obrázek 2.4: Vztahy mezi vlastnostmi a třídami RDFS

2.5 Ontologie

Znalostní modely, jež jsou popisované vyššími jazyky sémantického webu se označují jako ontologie. Ontologie ovšem není pouze abstraktním znalostním modelem, ale slouží i jako prostředek k získání interoperability, tedy schopnosti vzájemné spolupráce oddělených systémů na úrovni sdílení dat a poskytování služeb [21]. Definicí ontologie v informatice kterou uvádí Thomas Gruber, zakladatel ontologického inženýrství, je „formální specifikace sdílené konceptualizace“ [16]. V této definici je formálností myšleno vyjádření znalostí prostřednictvím jazyka s formálním a logickým základem. Pojem konceptualizace znamená definování konceptů na dané úrovni abstrakce, jež odpovídá požadavkům pro model domény. Tuto doménu pak vytvářejí osoby, pro které je daná ontologie závazně (vzájemnou dohodou) definovaná jako prostředek pro popis dat, jež musejí všichni členové dodržovat [21]. V důsledku se tak jedná o tvorbu abstraktního modelu v určené oblasti, kde se definují pojmy společně se vzájemnými vztahy vyjádřené logickým jazykem. Cílem explicitní specifikace pojmů a vztahů je snaha o porozumění znalostně orientovaných systémů [15]. Ontologie lze z hlediska vývoje rozčlenit do tří kategorií:

- **Terminologické (lexikální)** Slouží především ke zachycení taxonomie definovaných pojmů a popisu jejich vzájemných vztahů. Jejich realizace se často podobá slovníkům synonym.
- **Informační** Zastávají roli služby stojící nad databází, která zajišťuje vyšší míru abstraktnosti při databázovém dotazování.
- **Znalostní** Dovolují reprezentaci znalostí především v oblasti umělé inteligence, kde jsou chápány jako logické teorie, jejichž elementární prvky se definují prostřednictvím formálního jazyka. Využívají se zejména ve znalostně orientovaných systémech [19].

Dle míry formalizace a cílového předmětu konceptualizace se rozlišují 4 kategorie ontologie.

- **Doménové** Zabývají se specifikací určité oblasti – domény.
- **Generické** Blíží se svou podobou doménovým, ale pokrývají širší množinu dat a zachycují tak obecnější koncepty, nejdou ovšem do příliš velké hloubky. Popisují například realitu prostřednictvím vzájemných

časoprostorových pozic objektů. Často se snaží zachytit všeobecné znalosti, které odpovídají běžně používaným lidským vědomostem.

- **Úlohové** Tyto ontologie jsou zaměřené zejména na odvozovací procesy namísto záznamu znalostí a slouží především jako modely pro řešení určitých problémů – např. pro diagnostiku či plánování.
- **Aplikační** Jsou většinou vázány na specifické aplikace, kde spojují doménovou a úlohovou ontologii [19].

Pro realizaci popsaných ontologií je zapotřebí jazyka, který by dovoľoval formální zápis. Výše uvedené schéma RDFS je z hlediska sémantického webu základní podobou ontologie, kterou je dále možné rozšiřovat například využitím jazyků jako je OWL.

2.6 OWL

OWL (Web Ontology Language) je jazyk sémantického webu navržený pro získávání a zpracování informací prostřednictvím strojů (aplikací), namísto současného stavu, kdy jsou informace určeny pouze pro lidské uživatele. Tento jazyk využívá technologií XML, RDF a RDFS jakožto primárních prostředků pro tvorbu ontologických slovníků se základní sémantikou, kterou sám dále rozšiřuje o možnosti vyjádření složitějších výrazů a jejich vzájemných vztahů [24]. Mezi tato rozšíření patří například kardinalita, univerzální a existenční kvantifikace, matematické charakteristiky vlastností jako např. tranzitivnost, disjunktnost či inverze a anonymní třídy (sloužící často k jednorázovému využití) [17]. Vzhledem k tomu, že OWL nabízí poměrně pokročilou úroveň expresivity jazyka, je nutné brát v potaz výpočetní složitost algoritmů odvozovacích a usuzovacích nástrojů pracujících s vytvořenou ontologií. Z tohoto důvodu jsou specifikovány 3 varianty jazyka OWL, které se vzájemně liší mírou expresivity [21].

- **OWL Lite** Umožňuje definovat hierarchický systém tříd s jednoduchými omezeními vazeb [24]. Dále poskytuje prostředky pro zaznamenání symetrické, transitivní a inverzní vlastnosti a také jednoduchá omezení na velikosti množin vybraných objektů modelu – kardinalitu, která je ale v této verzi omezena pouze na přípustné hodnoty 0 a 1 [21].

- **OWL-DL** Tato varianta poskytuje maximální možnou expresivitu jazyka, u které je stále splněna podmínka rozhodovací úplnosti (jakékoliv rozhodovací pravidlo je možné použít na kteroukoliv část ontologie) a výpočetní splnitelnosti (veškeré výsledky odvozovacích operací budou získány v konečném čase) [21]. OWL-DL nabízí veškeré konstrukce jazyka OWL, které ale podléhají určitým omezením při jejich použití, např. není možné využít omezení kardinality pro vlastnosti definované jako tranzitivní. Z hlediska množiny dostupných jazykových konstrukcí dovoluje tato varianta oproti OWL Lite definovat navíc sjednocení, disjunkce a doplňky tříd nebo libovolné omezení kardinality [24].
- **OWL-Full** Je variantou, která poskytuje maximální možnou expresivitu, ke které využívá stejně jako předchozí verze všech konstruktů jazyka OWL. Tato varianta neklade žádná omezení pro vyhodnocovací pravidla, díky čemuž ale není možné zaručit výpočetní splnitelnost. OWL-Full dovoluje ještě navíc uživatelskou změnu sémantického významu nativně definovaných konstrukcí jazyků RDF a OWL. Tato verze ovšem není prakticky příliš využitelná, neboť v současnosti nejsou známe žádné efektivní algoritmy, které by dovolovaly nad modelem dat provádět usuzovací operace využívající všech vlastností OWL-Full [21].

Každá verze OWL je rozšířením svého předchůdce díky čemuž je ontologie vyjádřená v jednodušší variantě platná i pro verzi vyšší, např. tedy každá ontologie zapsaná ve OWL Lite bude plně validní ve OWL-DL (což ale obráceně neplatí) [24]. Mezi typické odvozovací úlohy v kontextu OWL patří například odvozování taxonomické struktury, ověřování příslušnosti instance ke třídě, klasifikace individuí vzhledem k definované ontologii či testování splnitelnost logické teorie [17].

2.7 SPARQL

Základním prostředkem pro dotazování nad daty sémantického webu je jazyk SPARQL (SPARQL Protocol and RDF Query Language). Tento jazyk standardizovaný konsorciem W3C umožňuje vytvářet dotazy nad RDF grafy prostřednictvím vzorů RDF trojic spolu s logickými operacemi konjunkce a disjunkce [21]. Konstrukce těchto dotazů je sice složitější než v případě SQL dotazů nad relačními databázemi, ale umožňuje ze zdrojové ontologie získávat komplexnější informace [20]. SPARQL dotaz se skládá ze 3 základních částí.

První část – označovaná jako prolog slouží k definování jmenných prostorů a prefixů, které budou v dalších částech dotazu použity. Druhou částí je hlavička dotazu, kde se určuje jaký typ dotazu se bude v další části provádět. Třetí a hlavní část SPARQL slouží k definování cílové ontologie (RDF grafu) pro dotazování (v případě, že cílový graf je implicitně definován, je tato část vynechána) a proměnných včetně samotných vyhledávacích podmínek v podobě grafových vzorů (graph pattern)[21]. Tento jazyk částečně vychází ze SQL, což je patrné i na jeho syntaxi. Např. klauzule FROM slouží pro výběr cílového grafu pro dotazování, či klíčové slovo WHERE slouží pro uvození zápisu souboru RDF trojic – tzv. grafového vzorce, jež je jádrem dotazu. Vyhodnocování dotazu poté probíhá takovým způsobem, že dochází k porovnávání grafového vzorce se s RDF daty [18]. Pro názornost je níže uveden zápis jednoduchého SPARQL dotazu, který slouží k vyhledání jmen a příjmení všech osob v implicitně zadaném grafu.

```
PREFIX zcu: <http://www.zcu.cz/ns/students>
SELECT ?name ?surname
WHERE {
    ?person x zcu:Person.
    ?person zcu:Name ?name.
    ?person zcu:Surname ?surname
}
```

SPARQL podporuje 4 druhy dotazů, které se vzájemně liší v typu vráceného výsledku [18].

- **SELECT** Tento typ dotazu nejvíce odpovídá běžnému SQL dotazování, neboť zadaným proměnným nastaví příslušné hodnoty a ty pak vrátí v podobě tabulky [28].
- **ASK** Dotaz typu ASK vrátí pouze TRUE/FALSE odpověď a slouží ke otestování, zda zadaný grafový vzorec má pro daný graf řešení. ASK tak slouží ke testování vytvořených logických hypotéz, ale neumožňuje už vrácení konkrétních řešení [18].
- **DESCRIBE** Dotazy typu DESCRIBE navrací podgraf dotazovaného grafu, který obsahuje všechny dostupné informace o zdroji, jež vyhověl zadanému grafovému vzoru [18]. Při vyhodnocování dotazů dochází ke porovnávání zdrojů získaných ze vstupního grafového vzoru se zdroji celého grafu. Pro nalezené odpovídající zdroje jsou pak získány všechny

vázané relevantní informace, ze kterých je ve výsledku složen navracený graf [28].

- **CONSTRUCT** Tento speciální druh dotazu navrácí jako výsledek nový RDF graf dle definované grafové šablony. Výsledný RDF graf je konstruován podle částečných řešení dotazovací sekvence, jež vyplňují proměnné ze zadané grafové šablony na základě které jsou tvořené výsledné trojice pro cílový navracený graf [18]. Tato dotazovací operace se do jisté míry podobá XSLT transformaci XML dokumentu.


3 EEG/ERP portál

EEG/ERP portál je webová aplikace, sloužící vědeckým pracovníkům k ukládání, stahování a vyhledávání EEG/ERP experimentů včetně jejich přidružených metadat. Tato aplikace je vyvíjena pro Katedru informatiky a výpočetní techniky Západočeské univerzity v Plzni. Portál funguje jako komplexní aplikace, která neslouží jen ke zpracování dat experimentů, ale poskytuje také funkce pro správu uživatelů, jež mohou mít odlišné role a také se sdružovat do výzkumných skupin jež mohou vzájemně spolupracovat. Portál je vyvíjen jako open-source aplikace pod GNU licencí. Jeho základní funkcionalitu je možné shrnout do několika následujících bodů [14].

- Ukládání, aktualizace a stahování naměřených dat experimentů včetně metadat
- Registrace nových uživatelů, sdružování do skupin včetně určení rolí
- Sdílení dat a metadat experimentů mezi výzkumnými skupinami
- Publikační a diskusní prostředky pro uživatele v podobě článků a jejich komentářů
- Fulltextové vyhledávání nad celou databází
- Přihlašování uživatelů skrze interní účty či prostřednictvím sociálních sítí
- Rezervace výzkumné laboratoře

3.1 Technologie portálu

Z technologického hlediska je EEG/ERP portál webová aplikace se standardní třívrstvou architekturou MVC (Model – View - Controler) - viz obrázek 3.1, běžící na aplikačním serveru Tomcat. Portál je vyvíjen v programovacím jazyce Java EE, přičemž při implementaci je využito několika frameworků, zejména pak Spring.



Obrázek 3.1: Architektura MVC

Prezentační vrstva je realizována prostřednictvím technologie JSP (Java Servlet Pages), zabezpečení a přihlašování uživatelů pak využívá frameworku Spring Security. Dále je pluginem Spring Social zajištěno prostřednictvím definovaného API propojení webové aplikace se sociálními sítěmi Facebook, Twitter a LinkedIn. Spring Social také slouží ke integraci možnosti přihlašování uživatelů prostřednictvím účtů zmíněných sociálních sítí.

Aplikační vrstva využívá zejména technologií Spring MVC a Spring Core a zajišťuje zpracování veškerých uživatelských požadavků pro ukládání a čtení dat, která získává z datové vrstvy. Persistentní data jsou uložena v relační databázi Oracle 11g, přičemž k jejich zpracování je použito objektově-relační mapování frameworku Hibernate. Ten využívá XML souborů pro mapování tabulek na POJO objekty, jež tvoří perzistentní vrstvu. Framework Hibernate zároveň umožňuje odstínit datovou vrstvu od implementační závislosti na zvolené databázi, jejíž případná obměna by následně nevyžadovala příliš velké zásahy do zdrojových kódů portálu [6].

3.2 Persistentní data

Databáze Oracle jež slouží ke ukládání persistentních dat uchovává veškeré naměřené hodnoty zaznamenaných experimentů. Tato data mají z pohledu databáze podobu binárních souborů s velikostí řádu desítek až stovek MB.


Tato naměřená data by ovšem ztrácela hodnotu, kdyby byla uchovávána jako samostatná. Proto databáze obsahuje další tabulky, jež nesou metadata prováděných experimentů. Kontext experimentu je popsán především hodnotami o prostředí laboratoře a zúčastněných osobami. Prostředí laboratoře je charakterizováno například teplotou, použitým hardwarem a softwarem. Nedílnou součástí popisu experimentu je také scénář zaznamenávající samotný postup měření, který má podobu binárního souboru. Dalšími důležitými daty jsou také informace o použitých elektrodách měřících EEG, u kterých je důležitý jejich typ a poloha. Co se týče osob účastnících se experimentu, zaznamenává se měřící a především měřená osoba. U osob jsou uchovávány osobní a kontaktní údaje a také data nutná pro přihlašování do portálu. Osoby se mohou sdružovat do různých výzkumných skupin, jež nesou seznam svých členů a vlastníka. Podstatným údajem jsou také identifikátory skupin vázané k hodnotám číselníků charakterizující vlastnosti experimentu, které tak napomáhají výzkumníkům zaznamenávat vlastní vybrané předdefinované hodnoty. Další tabulky ještě zaznamenávají historii stahování, zveřejňované články a jejich textové komentáře. Rezervace laboratoře obsahuje údaje o počátečním a koncovém času události a také rezervující osobě.

4 Relační datový model

Jak již bylo zmíněno v předchozí kapitole, webová aplikace EEG/ERP portál uchovává data v relační databázi – lze na ně tedy pohlížet jako na relační datový model. Vzhledem k tomu, že další část práce se bude zabývat úpravou současného datového modelu portálu, bude vhodné uvést zde základní popis a vlastnosti obecného relačního modelu.

Základem relačního modelu dat, který byl popsán již v roce 1970 je takzvaná relace neboli tabulka [5]. Z matematického hlediska můžeme n -ární relaci chápat jako libovolnou podmnožinu kartézského součinu n množin [22]. Množinou je zde myšlena doména jednoho konkrétního sloupce tabulky, tedy všechny přípustné hodnoty, kterých může libovolný řádek v daném sloupci tabulky nabývat. V důsledku tedy máme tabulku tvořenou n sloupci (n -ární relace) a x řádky, kde každý řádek reprezentuje jeden prvek z množiny tvořené kartézským součinem n množin. V případě, že by každá z n množin byla konečná (řádky daných sloupců mohou nabývat konečného počtu hodnot), bude konečný i kartézský součin těchto množin a tabulka tak může mít jen konečný a tudíž omezený počet neopakujících se řádek (duplicity v tabulce neuvažujeme, neboť by neměly žádný smysl – jednalo by se o redundantní data) [22].

Uvedená reprezentace matematického pojmu relace jako databázové tabulky je základem takzvaného schéma relace. Toto schéma obsahuje název relace, jména všech atributů (sloupců tabulky) a jejich integritních omezení – tedy domény [4]. Domény jednotlivých atributů jsou v systémech řízení báze dat reprezentovány datovými typy, tedy např. číselný typ, textový řetězec či datum. Tabulku lze tedy chápat jako určitou formu znázornění relace [7]. Jedna tabulka slouží zpravidla k uchování údajů o jednom druhu objektů [9]. V případě portálu tak například tabulka *Person* uchovává pouze data o osobách – jeden řádek neboli záznam tedy reprezentuje údaje o jednom člověku, které jsou strukturované do sloupců, např. jméno, příjmení, email apod. Názornější představu konkrétní relace je možné získat z obrázku 4.1. Aby bylo možné s daty tabulky pracovat, zavádí se aparát, který zajišťuje jednoznačnou identifikaci každého záznamu - primární klíč. Primární klíč je atribut či skupina atributů, která je pro každý záznam tabulky jedinečná (stejně jako název tabulky v databázi) [9]. V případě zmíněné tabulky *Person* by tak mohl posloužit například atribut email, neboť žádné dvě osoby nemohou logicky mít stejnou emailovou adresu (což by mělo být zajištěno ze strany



Obrázek 4.1: Znázornění relace

domény dané emailové adresy). V případě že tabulka neobsahuje žádný atribut, který by potřebnou jedinečnost záznamů zajišťoval, je nutné jej přidat. To je realizováno např. atributem ID, obsahujícím číslo z číselníku, jehož hodnota je inkrementována po každém přidání dalšího záznamu do tabulky *Person*. Tento identifikátor položky sice jednoznačně určuje daný záznam v tabulce, nikoliv už však v rámci celé databáze (pokud uvažujeme více tabulek) či vně databáze. V jedné databázi je tedy možné mít například tabulky *Person* a *Experiment*, jejichž primárními klíči bude atribut s názvem ID typu celého čísla. V takovém případě je pak i možné aby obě tabulky obsahovaly 2 různé záznamy jež budou jednoznačně identifikovatelné stejnou číselnou hodnotou (ale v kontextu dané tabulky). Z toho důvodu je pro jednoznačnou identifikaci záznamu nutné znát jak hodnotu příslušného atributu obalující relace, tak i její název.

4.1 Limity relační databáze

4.1.1 Dědičnost

Relační databáze může samozřejmě obsahovat větší množství tabulek (za předpokladu že mají vzájemně různé názvy). Každá tabulka tak sdružuje záznamy, jejichž obsah si je v určitém smyslu blízký. Z hlediska objektově orientovaného přístupu, který je realizovaný např. nástrojem Hibernate, lze tabulku chápat také jako třídu a její záznamy jako instance dané třídy. Každá takováto instance má pevně daný počet atributů, který je definován obalující třídou. Uvažujme například tabulku *Person*, která ponese údaje jak o osobách které jsou cílovým objektem experimentů tak údaje o výzkumných pracovnících. U obou skupin nás budou zajímat společné atributy jako jméno a příjmení, ale některé atributy budou různé. U testovaných osob to bude např. věk, zatímco u výzkumníků např. titul. Uvažujeme-li objektový přístup k takovéto tabulce, můžeme využít dědičnosti. Vytvoříme tedy třídu *Person*, která ponese všechny společné atributy a od ní bude zděděna třída pro výzkumníky a třída pro testované osoby. Tyto třídy budou obsahovat atributy, které jsou specifické pro danou skupinu. Z pohledu relačního modelu je tento problém řešitelný obtížněji. Je možné například vytvořit 2 samostatné tabulky pro dané skupiny či ponechat jednu tabulku, která ponese všechny atributy a každá skupina bude mít vyplněna jen jejich část. Podobný problém by vznikl například při potřebě dodat další atribut jen omezenému počtu osob jedné ze skupin. Z uvedeného příkladu je patrné, že dynamické rozšiřování záznamů obsažených v jednotlivých tabulkách je poměrně obtížné.

4.1.2 Vztahy mezi relacemi

Relační model dovoluje také zaznamenávat vztahy mezi jednotlivými tabulkami a provazovat tak záznamy z různých tabulek. Tyto vazby se realizují prostřednictvím atributů označovaných jako cizí klíč [9]. Hodnotou cizího klíče je pak hodnota primárního klíče tabulky, která je cílem vytvářené vazby. Z hlediska kardinality vztahu je možné rozlišit 3 základní případy $1:1$, $1:N$ a $M:N$ [3]. Vztah $1:1$ vyjadřuje případ, ve kterém záznam jedné tabulky odpovídá záznamu jinému tabulky. Tento případ není příliš častý a většinou se řeší umístěním obou záznamů do jediné tabulky. Vztah $1:N$ reprezentuje situaci, kdy se jednomu záznamu tabulky přiřazuje více záznamů jiné tabulky. Příkladem takové vazby může být vztah záznamů tabulek *Person*

a *Reservation*. Jedna osoba tedy může mít N rezervací laboratoře, ale každá rezervace má jako vlastníka právě jednou osobou. V modelu je tato informace realizovaná přidáním atributu *person_id* do tabulky *Reservation*. Tento atribut se tak stává cizím klíčem a ponese hodnotu primárního klíče tabulky *Person* pro příslušný záznam cílové osoby. Samotná vazba tedy obsahuje informaci o zdrojové záznamu, cílovém záznamu a také název vazby který je reprezentován názvem atributu pro cizí klíč tabulky.

Posledním druhem vazby je vztah $M:N$, jež slouží k reprezentaci stavu, kdy M záznamům jedné tabulky odpovídá N záznamů jiné tabulky. Tento stav je v relačním modelu řešen rozložením na dvě vazby $1:N$ a $1:M$, které jsou pak realizovány vytvořením další tabulky, jejíž záznamy budou obsahovat cizí klíče obou tabulek. Pro realizaci takové vazby je tedy nutné vložit do databáze další tabulku a v případě potřeby rozlišení druhu jednotlivých vazeb je zapotřebí buď dalšího atributu jež by vztah popisoval, či pro každý druh vazby mít vlastní tabulku (což se týká i případu vazby $1:N$). Pokud by ovšem bylo zapotřebí popsat také vztahy mezi jednotlivými vazbami nastává problém, který je řešitelný velmi obtížně [9].

4.2 Datový model EEG/ERP portálu

Současnou podobu relační databáze portálu tvoří přibližně 80 tabulek. Naměřená data experimentů (hodnoty EEG signálů) jsou uložena v podobě binárních souborů v tabulce *DATA_FILE*, spolu se popisnými údaji jako je název či datový typ mající podobu textového řetězce nebo čísla. Tyto popisné údaje lze označit jako metadata binárního souboru naměřených dat. Metadata scénáře experimentu uložená v tabulce *SCENARIO* obsahují popisné informace dalších binárních souborů, jež jsou uloženy v tabulce *SCENARIO_TYPE_NONXML* obsahující popis průběhu měření. Obě tabulky *SCENARIO* a *DATA_FILE* obsahují vazbu na tabulku *EXPERIMENT*, která obsahuje buď přímo metadata experimentu (nikoliv však souboru naměřených dat) nebo zajišťuje provázání s jinou tabulkou jež je nese. Z aktuálního modelu je patrné, že jeden experiment je popsán jedním scénářem, ale může obsahovat více (binárních) souborů naměřených dat.

Tabulka *EXPERIMENT* s klíčovými metadaty obsahuje také dvě vazby na tabulku *PERSON*, jež slouží ke zaznamenání měřené osoby a experimentátora (vlastníka experimentu). Z hlediska datového modelu není mezi těmito osobami rozdíl, neboť jsou všechny uloženy v jediné tabulce a tudíž jsou všechny osoby

popsány stejnou množinou atributů. Některé testované osoby například vůbec nemusejí potřebovat přístup do portálu, ale tabulka ve které jsou zaznamenány obsahuje atributy uživatelského jména a hesla (i když mohou nabývat hodnoty NULL). Stejná situace nastává i pro další referencované tabulky *ARTICLES*, *ARTICLES_COMMENTS* či *RESERVATION*. Datový model tak nikterak nezabraňuje, aby měřené osoby měly své články, přidávaly k nim komentáře nebo rezervovaly laboratoř (vychází se z předpokladu, že portál slouží zejména pro výzkumné pracovníky, nikoli pro testované osoby).

Obdobná situace nastává v případě tabulky *RESEARCH_GROUP*, sloužící ke sdružování osob do výzkumných skupin. Její vazby na tabulku *PERSON* zajišťují, že každá skupina má svůj název, popis a také vlastníka. Každá skupina může mít samozřejmě více členů, což zajišťuje rozkladová tabulka *RESEARCH_GROUP_MEMBERSHIP*, jež obsahuje i roli člena ve skupině (ve smyslu uživatelský práv). Samotná tabulka ovšem poměrně značně zasahuje do celého datového modelu, díky množství rozkladových tabulek sloužících ke kategorizaci hodnot specifických metadat experimentů ke vybraným skupinám. Díky tomu je možné, aby vybraná skupina mohla definovat pro své potřeby vybrané hodnoty pro určitá metadata – např. pro tabulku *HARDWARE* definovat množinu přístrojů, které ke svým výzkumům využívá. Díky rozkladovým tabulkám může navíc více skupin sdílet stejné hodnoty položek hardware. Tyto tabulky s dodatečnými metadaty experimentu jako například zmíněný *HARDWARE*, *SOFTWARE* či *WEATHER* sice popisují kontext měření, ale z hlediska datového modelu se jedná pouze o nekategorizovaná data vázaná (často nepřímo) na tabulku *EXPERIMENT*. Není tedy možné sdružit některé parametry měření do skupin – např. tabulky *PHARMACEUTICAL* a *DISEASE* označit jako medicínské parametry s specifikovat tak jednoduchou hierarchickou kategorií metadat experimentů.

Další problém, který řeší současný relační datový model jen částečně je dynamická rozšiřitelnost struktury dat (ve sémantickém smyslu). V průběhu vývoje portálu se postupně zvyšoval počet tabulek nesoucích specifická metadata experimentu a je i nadále rozšiřován. Pro případ vzniku potřeby popisu daného experimentu parametrem, jenž není definován jako atribut tabulky *EXPERIMENT* ani jinou samostatnou tabulkou, obsahuje databáze tabulky *EXPERIMENT_OPT_PARAM_DEF* a *EXPERIMENT_OPT_PARAM_VAL*. Ty umožňují zaznamenat další hodnoty ve tvaru parametr-hodnota a navíc je sdílet pro více skupin. Nevýhodou tohoto řešení je ale absence možnosti přidat danému parametru více klíčů (chceme-li se vyhnout změně tabulky přidáváním dalších atributů), či tyto údaje ještě více řetězit. Obdobná situace však nastává i v případě samostatných tabulek pro konkrétní metadata

experimentu.

Pro bližší představu o současném datovém modelu portálu je možné nahlédnout do přílohy A obsahující ERA model EEG/ERP portálu.

5 Datový model sémantického webu

Předchozí kapitola se zabývala daty, která jsou sdružovaná a reprezentována prostřednictvím relačního modelu. Stejná data ovšem mohou být také uchována prostřednictvím databáze založené na modelu sémantického webu, jemuž bude věnována tato kapitola. V kapitole sémantického webu byla nastíněna koncepce sémantického webu, včetně reprezentace dat. Reprezentací datového modelu sémantického webu je takzvaný RDF graf, který sestává z libovolného počtu RDF výrazů neboli trojic. Každá trojice je tvořena subjektem, predikátem a objektem, které jsou z pohledu sémantického webu dále nedělitelné [16]. Jedna trojice tak poskytuje jednu elementární informaci o jednom subjektu. Zda-li má objekt trojice podobu jedinečné konkrétní entity už je určeno tím, jestli je reprezentován URI identifikátorem, či se jedná pouze literál nebo anonymní list (blank node). Odlišná situace nastává u subjektu, který může být buď URI identifikátorem nebo anonymním listem. Reprezentace literálem zde již není možná, neboť by se popírala možnost provázání jednotlivých entit trojic, což je klíčová vlastnost sémantického webu [15].


Podstatný rozdíl mezi datovým modelem sémantického webu oproti modelu relačnímu je absence jakýchkoliv tabulek. Struktura dat tak není předem specifikována a je tak možné vytvářet v podstatě objektový model jehož vnitřní uspořádání sice může být na první pohled méně přehledné až chaotické ve srovnání s relační variantou, ale tento model je z hlediska struktury dat samopopisný. Záznamy relační databáze sice nabývají významu díky kontextu tabulky resp. jejích atributů, ale sémantické informace o vzájemném vztahu více záznamů různých tabulek už chybí. V datovém modelu jenž je tvořen systémem provázaných trojic jsou sice elementární informace uloženy v jednotlivých tripletech, ty ale získávají další informační hodnotu díky kontextu s nimi provázaných trojic. V důsledku tohoto faktu tak každá neizolovaná elementární informace (trojice) v modelu obsahuje sémantickou informaci o vztahu s ostatními daty. Datový model tak ve výsledku obsahuje jak cíleně uložená data (ve smyslu relační databáze) tak i jejich vzájemný kontext, který navíc vytváří z modelu organizovaný systém.

5.1 Dynamičnost modelu

Z výše uvedených informací je patrné, že datový model sémantického webu je oproti relačnímu snáze rozšiřitelný a je tak vhodnější pro uchování dat jejichž struktura je v sémantickém smyslu více heterogenní. Bude-li například potřeba vytvořit databázi většího množství osob, které se dále člení na určité skupiny jež se liší sledovanými parametry na úrovni skupin i jednotlivců je v principu možné řešit problém dvěma způsoby. Vytvořením relačního modelu je možné kategorizovat osoby prostřednictvím tabulek respektive jejich atributů, které ale bude nutné dále rozšiřovat s rostoucím počtem nových odlišných skupin a měnit tak do jisté míry pevnou strukturu dat. V případě řešení prostřednictvím sémantického webu je možné přidávat specifické informace pouze vybraným skupinám či jednotlivcům, aniž by se muselo zasahovat do struktury ostatních dat. Je tak možné organizovat jednotlivé objekty (osoby) do různých i prolínajících se skupin a ty popisovat hromadně nezávisle na ostatních, což je myšlenka dědičnosti.

5.2 Dědičnost a hierarchie dat

Jazyk RDFS zavádí do datového modelu sémantického webu základní organizační hierarchii. Uložené objekty je možné kategorizovat do jednotlivých tříd stejně jako vlastnosti a ty pak vzájemně hierarchicky organizovat. Jednotlivé objekty tak můžou dědit od svých předků (díky konstrukcím *rdfs:range* a *rdfs:domain*) určité vlastnosti a na své úrovni je sami dále rozšiřovat. Celý tento princip je možné popsat na jednoduchém příkladu znázorněném na obrázku 5.1. Třída (*rdfs:Class*) *Person* jež definuje dvě vlastnosti (*rdf:Property*) *name* a *surname* má dva potomky (*RDFS:SubclassOf*), jež tyto vlastnosti dědí. Potomek *Experimenter* dále rozšiřuje své vlastnosti o atribut *Email* a potomek *Subject* definuje atribut *Age*. Informace, že experimentátor *Pavel* (jenž je instancí třídy *Experimenter*) provádí měření na objektu *Martin* je zachycena predikátem (*rdf:Property*) *Measure*. Inverzní činnost „je měřen“ popisuje vlastnost *IsMeasured*, přičemž definice inverzního vztahu dovoluje vyjádřit jazyk OWL.



Obrázek 5.1: Znáznornění hierarchické organizace dat

5.3 Problémy modelu

Jak již bylo zmíněno, tato podoba modelu je výhodná spíše v případech velké různorodosti uchovávaných dat, pro homogenní a z hlediska rozšiřování statická data je stále výhodné řešení využívající tabulek. Sémantický web však slouží především k uchovávaní metadat, původní data jež by mohla mít podobu větších binárních souborů by bylo obtížné ukládat tímto způsobem. Technologie a standardy sémantického webu definují datové typy prostřednictvím schématu jazyka XML, jenž sice připouští také binární typy např. `base64Binary`, ale pravděpodobně není vhodné je využít pro uložení většího binárního souboru do tohoto datového modelu z důvodu výkonnosti a sémantické využitelnosti v rámci modelu [29].

5.4 Porovnání modelů

Pro jednoduché porovnání datového modelu sémantického webu a relačního datového modelu poslouží níže uvedená tabulka 5.1, jež srovnává výhody (+)

a nevýhody (-) obou modelů.

	Relační model	Model sémantického webu
Dědičnost	+	-
Dynamická rozšiřitelnost modelu	+	-
Typování meziobjektových vazeb	+	-
Unifikace identifikátorů objektů	+	-
Hierarchická organizace dat	+	-
Sémantika datového modelu	+	-
Ukládání rozsáhlých datových objektů	-	+
Uchování (sémanticky) homogenních dat	-	+
Počet dostupných nástrojů pro uchování persistentních dat	-	+

Tabulka 5.1: Srovnání výhod a nevýhod datových modelů

Z výše uvedené tabulky je patrné, že vhodnost použití vybraného modelu je odvislá od typu a struktury dat, jež by měl datový model uchovávat. Jednotlivé řádky tak stručně shrnují vhodnost modelu pro vybranou vlastnost uchovávaných dat. Poslední položkou je počet dostupných nástrojů umožňujících uchování persistentních dat, kterou je míněno množství softwarových řešení databázových úložišť umožňujících uchování dat ve vybrané, modelu přirozené podobě. Pro relační databáze je takových nástrojů poměrně široká řada, ale pro úložiště dat sémantického webu je výběr o poznání menší, navíc mnoho z těchto dostupných nástrojů je spíše experimentálního charakteru. Jejich popisu a výběru se věnuje následující kapitola.

6 Nástroje pro vývoj sémantického webu

Jak již bylo zmíněno v kapitole Sémantický web, jazyk RDF je jedním ze základních stavebních prvků technologie sémantického webu. Současná podoba tohoto jazyka vychází ze specifikace W3C [23] z února 2004. Za dobu uběhlou od publikace zmíněné specifikace do současnosti (2013) vznikla poměrně široká sada nástrojů od jednoduchých utilit až po komplexní softwarová řešení jež umožňují zpracovávat data v jazyce RDF resp. OWL. Rozsáhlý a vcelku přehledný seznam těchto nástrojů (k datu vzniku této práce celkem 183) dostupný ze zdroje [2] poslouží jako primární seznam pro výběr vhodného nástroje. Pro účely této práce se zaměříme na hledání nástroje jež slouží primárně jako persistentní úložiště RDF dat a zároveň poskytuje veřejné Jena/Sesame API pro komunikaci a umožňuje dotazování jazykem SPARQL nad daty. Další nutnou podmínkou je, aby nástroj poskytoval hybridní úložiště umožňující uchovávat jak relační data tak data v jazyce sémantického webu (zmíněné požadavky vyplývají z následující kapitoly). Tyto poměrně náročné podmínky ovšem splňují pouze dva nalezené nástroje, jejichž popis bude následovat.

6.1 Virtuoso

Virtuoso je hybridní databázový server umožňující práci nad více datovými modely. Nástroj poskytuje klasickou relační databázi, RDF databázi trojic, XML databázi a také dokumentově orientovanou databázi. Verze aplikace se zpoplatněnou licencí poskytuje oproti GPL licencované variantě navíc virtuální databázi a také replikaci dat. Virtuální databáze umožňuje zastřešit více databázových systémů jediným centrálním se kterým klient komunikuje. Ve výsledku tak umožňuje klientovi pracovat s více databázemi, které se mu transparentně jeví jako jediná. Díky tomu je například možné prostřednictvím jediného dotazu získat výsledek ze všech databází najednou. Replikace dat slouží k zajištění konzistence dat takovým způsobem, kdy při např. dvou databázích slouží hlavní databáze k zachycení aktuálních změn dat, které postupně zasílá vedlejší databázi jež obsahuje původní data. Díky tomu obsahuje vedlejší databáze stále konzistentní data neboť při nezdařeném zápisu aktualizace může zažádat hlavní databázi o jejich opětovné zaslání.

Databázový server poskytuje grafické webové rozhraní, které slouží ke komplexní administraci a také je možné jeho prostřednictvím zadávat libovolné SQL/SPARQL dotazy. Virtuoso implementuje nad relační databází engine poskytující funkcionalitu v podobě standardu SQL-92, podporu pro pohledy, standardní datové typy, procedury, kurzory a také transakce. SPARQL dotazy je možné zadávat stejnými prostředky jako SQL dotazy, či je dokonce vnořovat do SQL dotazů. Díky tomu je možné pracovat s relačním modelem dat a RDF modelem zároveň. Samotné dotazování a další komunikace klientské aplikace se serverem může být realizováno prostřednictvím driverů ODBC/JDBC nebo Java knihovnou poskytující Jena API. Neméně důležitou součástí podpory Java aplikací je i distribuce knihoven pro Hibernate (Hibernate driver a Hibernate dialect). Virtuoso také podporuje import souborů s RDF daty ve formátu N3, Turtle a také nejběžnější RDF/XML [11].

6.2 Oracle 11g - Oracle Spatial

Oracle Spatial je rozšířením databázového systému Oracle, jež je primárně určeno pro zpracování geoprostorových dat [13]. Toto rozšíření s sebou ovšem přináší také podporu pro sémantické technologie, která je klíčová pro tuto práci. Standardní instalace Oracle 11g release 2 (současná databáze EEG/ERP portálu), ani žádná z předchozích verzí tuto podporu standardně po instalaci neposkytuje. Její zapnutí je ale pouze záležitostí spuštění instalačního skriptu a následného vygenerování tabulkového prostoru pro systémové tabulky a všechna následně ukládaná data. V tomto tabulkové prostoru je již možné vytvořit sémantickou síť, která ponese všechny systémové RDF tabulky a pohledy, jež jsou nezbytné pro provádění SPARQL dotazů. Při práci s databází je zapotřebí mít k dispozici datový model, který ponese všechny RDF trojice, jež budou vytvářeny. Tento model bude vázán na tabulku, která ponese všechny vytvářené trojice. Do tohoto modelu je již možné zapsat první trojici [12]. Pro názornost jednoduchosti tohoto procesu bude uveďte výše popsany postup v podobě SQL příkazů [12].

1. `~/md/admin/catsem11i.sql`
2. `CREATE TABLESPACE rdf_tblspace DATAFILE
'/oradata/orcl/rdf_tblspace.dat' SIZE 1024M AUTOEXTEND
ON NEXT 256M MAXSIZE 16384M;`
3. `EXECUTE SEM_APIS.CREATE_SEM_NETWORK('rdf_tblspace');`
4. `CREATE TABLE family_rdf_data (id NUMBER,`

```
triple SDO_RDF_TRIPLE_S);  
5. execute SEM_APIS.create_sem_model('family',  
   'family_rdf_data', 'triple');
```

První příkaz instaluje podporu sémantických modelů v databázi. Druhým příkazem je na disku vytvořen sobor, který ponese tabulkový prostor pro sémantickou síť a všechny datové modely. Jeho počáteční velikost je nastavena na 1 GB s možností dalšího zvětšení v případě vyčerpání dané kapacity. V tomto tabulkové prostoru je ve třetím kroku vytvořena sémantická síť, ve které je možné vytvářet jednotlivé datové modely. Ve čtvrtém kroku je vytvořena první tabulka se dvěma sloupci, kde se vyskytuje nový datový typ *SDO_RDF_TRIPLE*. Jedná se o datový typ trojice ve smyslu RDF, který v sobě obsahuje subjekt, predikát a objekt (dle očekávaného standardu). Posledním příkazem byl vytvořen datový model nad předchozí tabulkou, který poslouží pro ukládání konkrétních trojic. Samotné vkládání trojic je pak poměrně jednoduché, a je možné jej nalézt ve [12].

Po instalaci podpory sémantických technologií je již tedy možné využívat databázi Oracle jako úložiště RDF dat. Ve výsledku je tedy k dispozici hybridní databáze pro ukládání dat jak v relační podobě tak ve RDF jazyce. Nad zmíněnými sémantickými daty je možné se dotazovat jazykem SPARQL a to skrze stejné prostředky jako v případě jazyka SQL. V důsledku toho je také možné vytvářet vnořené či jinak kombinované dotazy z obou jazyků, stejně jako tomu bylo u nástroje Virtuoso. K sémantickým datům databáze je možné přistupovat samozřejmě stejnou cestou jako k relačním – tedy prostřednictvím ODBC/JDBC driveru, ale Oracle také dodává driver poskytující standardní Jena API pro Java aplikace. Databázový systém podporuje odvozovací pravidla jazyka RDF, RDFS i OWL a od verze Oracle 10g je navíc možné, aby uživatel definoval vlastní odvozovací pravidla. Při vytváření dotazu je pak možné určit jakou množinu odvozovacích pravidel (RDF / RDFS / vlastní pravidla či jejich kombinace) chceme do dotazu zahrnout a ovlivnit tím tak jeho výsledek [12].

6.3 Jena

Jena je Java framework určený pro vývoj aplikací sémantického webu. Nástroj je vyvíjený od roku 2000 v podobě open source projektu, který je nyní dostupný pod Apache licenci. Framework Jena je distribuovaný jako knihovna jež poskytuje [1]:

- API pro zápis a čtení RDF dat ve formátu N3, RDF/XML či N-triples
- API pro práci s ontologiemi na úrovni jazyků RDFS a OWL
- Reasoner pro zpracování dat jazyků RDF a OWL
- Dotazovací engine SPARQL
- Ukládání RDF dat do databáze

Jena poskytuje komplexní API umožňující práci s daty sémantického webu. Veškerá zpracovávaná data, jež mají podobu grafu, jsou uchovávána prostřednictvím modelu. Framework poskytuje 2 druhy modelů, jež se liší svou expresivitou. Základní model umožňující zpracování dat na úrovni jazyka RDF je vhodný pro data s nízkou úrovní sémantiky. Druhý, ontologický model umožňuje maximální využití nástroje, neboť poskytuje API pro práci s ontologiemi jazyka OWL. Samotný model je možné uchovávat buď pouze v paměti, přičemž je možné jeho data ukládat i opětovně načítat ze souboru, nebo v databázi, která poskytuje příslušný konektor umožňující využití Jena jako API k tomuto úložišti. S daty modelu je možné pracovat objektovým způsobem na úrovni trojic či jejich částí nebo prostřednictvím vykonávání SPARQL dotazů [1].

7 Transformace datového modelu

7.1 Rozdělení datového modelu

V předchozích kapitolách jež se zabývaly datovým modelem sémantického webu a relačním datovým modelem bylo možné získat základní představu o obou možnostech reprezentace dat. Rovněž byly nastíněny některé problémy současného relačního datového modelu portálu, jehož úprava je předmětem této práce. Z výše uvedené tabulky 5.2 je patrné že technologie sémantického webu využitě pro reprezentaci datového modelu mají i nevýhody, a to zejména v oblasti ukládání rozsáhlých datových objektů, jež je primárním důvodem pro částečné zachování relačního modelu. V rámci této práce tedy bude navržen datový model EEG/ERP portálu, který bude z jedné části založený na relační databázi a z druhé části na objektově orientované databázi využívající technologie sémantického webu, bude se tedy jedna o hybridní datový model.


Pro rozdělení datového modelu je nutné určit pravidla, podle kterých bude rozdělení provedeno. K tomu bude využito koncepce sémantického webu, který je určený zejména pro ukládání a zpracování metadat. V současném datovém modelu je tedy nutné odlišit základní data od metadat. Následující rozdělení zároveň umožní vyřešit problém ukládání rozsáhlých datových souborů, neboť právě ty budou označeny jako základní data. Na EEG/ERP portál je možné pohlížet jako na aplikaci poskytující prostředky pro ukládání a zpracování experimentů a zároveň umožňující diskusní činnost uživatelů aplikace. Každý prováděný experiment je z pohledu databáze charakterizován dvěma základními objekty – binárním souborem zaznamenávajícím naměřené hodnoty a souborem scénáře, který určuje postup měření. Diskusní funkcionality portálu umožňuje uživatelům vytvářet textové příspěvky v podobě článků jež mají charakter rozsáhlejšího textového objektu a k těmto článkům mohou další uživatelé přidávat komentáře stejného datového typu. Popis této funkcionality portálu tak v důsledku umožňuje identifikaci základních dat jejichž úložištěm bude relační databáze. V ERA modelu portálu, jež je uveden v příloze A této práce, jsou zmíněné údaje uchovány v tabulkách v podobě rozsáhlých binárních/textových souborů. V relačním modelu tedy ponecháme uchovaná tato data:

- Datové soubory se záznamem experimentu

- Datové sobory se scénářem popisujícím postup experimentu
- Text článků publikovaných uživateli portálu
- Text komentářů publikovaných článků

7.2 Relační část modelu

Relační část datového modelu bude tvořena čtyřmi tabulkami z nichž každá ponese příslušná data dle výše uvedeného seznamu. Z důvodu jednoduchosti budou názvy tabulek převzaty z původního modelu dle původních tabulek nesoucí tato data. Aby bylo možné jednotlivé tabulkové záznamy jednoznačně identifikovat bude do tabulky přidán sloupec nesoucí tento údaj. Pro zachování koncepce sémantického webu ve výsledném modelu však nebude tímto identifikátorem pouze postupně inkrementované číslo jako v původním modelu, nýbrž se zavede identifikace prostřednictvím URI. Tímto způsobem dosáhneme jednotné identifikace objektů v celém výsledném datovém modelu, přičemž záznamy relační databáze jednoznačně označené prostřednictvím URI budou dále popisovány v datovém modelu sémantického webu, jež bude sloužit k uchování metadat. Ve výsledku tak zmíněná identifikace údajů prostřednictvím URI zajistí propojení obou částí cílového datového modelu. ERA model relační části nově vytvářeného modelu na obrázku 7.1 je pak poměrně jednoduchý ve srovnání s původní variantou díky absenci uchování metadat.



Obrázek 7.1: ERA model relační části transformovaného modelu

Následující vytvářená sémantická část modelu bude provádět transformaci původního relačního modelu, z jehož tabulek nesoucích zmíněné datové soubory jsou ty atributy odstraněny (z důvodu jejich přesunu do této nové relační části modelu).

7.3 Sémantická část

Zbývá část dat původního modelu jež nebude obsažena ve relační části nového modelu je předmětem následující transformace. K jejímu provedení je potřeba nadefinovat obecná pravidla a postup, který by umožňoval transformaci obecnějšího modelu z důvodu jeho častých změn. I v průběhu tvorby této práce je původní model nadále modifikován a je tak zapotřebí mít k dispozici postup, který by umožnil vytvoření i úpravu nového hybridního modelu tak, aby pokrýval stejnou množinu dat jako původní model v později modifikované verzi. Postup vytvoření nového modelu bude sestávat ze dvou částí a to z transformace původních dat do podoby sémantického webu a z dodání sémantiky tomuto modelu, tak aby mohl být do jisté míry samopopisný. Pro popis resp. zápis této části modelu budou využity jazyky RDF spolu se RDFS, které dovolují vyjádřit veškerou sémantiku nalezenou v aktuálním modelu.

7.3.1 Transformace tabulek

Při transformaci tabulek původního relačního modelu bude využito obdobného principu jako v případě objektově relačního mapování nástroje Hibernate [8]. Prvním krokem je identifikace původních tabulek, které neslouží pro rozložení vazby M:N mezi jinými tabulkami. Tyto tabulky budou v nově vznikajícím modelu představovat třídy a záznamy v nich obsažené budou reprezentovány instancemi těchto tříd. To je možné díky jazyku RDFS, který dovoluje vytvářet jednoduchý objektový model složený z tříd a jejich instancí podobně jako např. v jazyce Java. Jednotlivé atributy tabulek pak budou realizovány jako predikáty (*rdf:Property*). Transformace struktury původní tabulky prostřednictvím jazyka RDF resp. RDFS se zajistí jazykovými konstrukcemi tak, jak je uvedeno v tabulce 7.1.

Každá takto transformovaná tabulka bude reprezentována jedním URI identifikátorem (stejně jako další objekty) a označení, že se jedná o třídu zajistí konstrukce *rdfs:Class*. Původní název tabulky bude součástí hodnoty

URI. Každý záznam tabulky bude rovněž popsán prostřednictvím URI a jeho náležitost ke třídě (je instancí třídy) popíše trojice, kde subjektem bude URI této instance, predikátem konstrukce *rdf:type* a objektem URI cílové třídy. Jednotlivé atributy tabulky se díky konstrukci *rdf:Property* stanou predikáty ve vytvářeném modelu a umožní tak vytvářet typovanou vazbu mezi instancemi a hodnotami jejich atributů (literálů) či mezi instancemi navzájem.

Tabulka	<i>rdfs:Class</i>
Záznam tabulky	<i>rdf:type</i>
Atribut tabulky	<i>rdf:Property</i>

Tabulka 7.1: Transformace strukur tabulky do sémantického webu

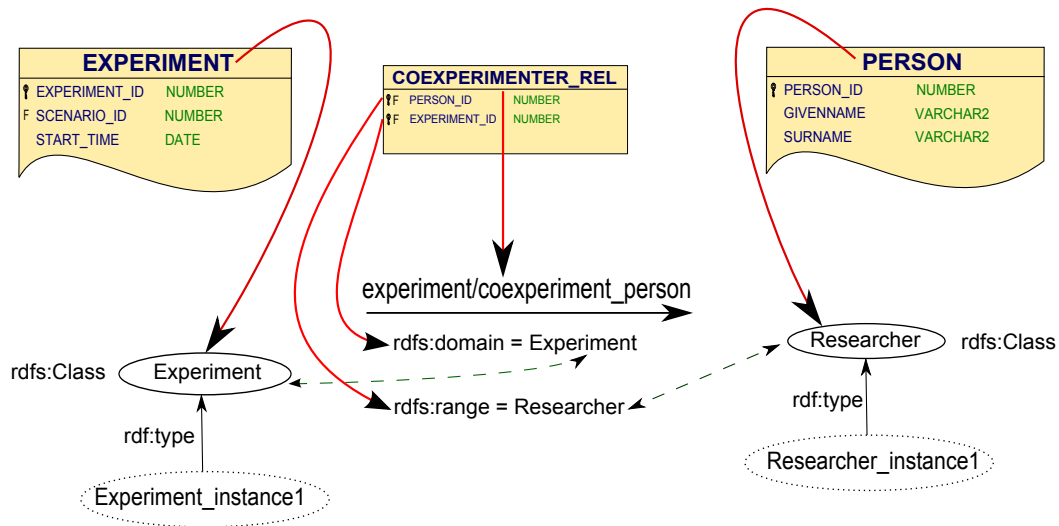
Transformované atributy (predikáty) je zapotřebí navíc svázat se třídami původních tabulek těchto atributů. Toho se docílí díky konstrukci *rdfs:domain*, která tak de facto určuje doménu těchto predikátů. Tento výraz ale především slouží k definování náležitosti instance ke své třídě, čehož se docílí vytvořením trojice jejímž predikátem bude transformovaný atribut a subjektem zmíněná instance.

7.3.2 Transformace rozkladových tabulek

Původní datový model je z velké části tvořen tabulkami jež rozkládají násobnou vazbu M:N jiných tabulek. Tyto tabulky nebudou transformovány do podoby tříd, nýbrž se pouze využijí jejich atributy, které budou přiřazeny k jedné z provázaných tabulek resp. tříd. Sémantický web připouští přiřazení více různých hodnot objektů subjektům pro stejný predikát. Je tedy možné například instanci třídy *Weather* přiřadit pro predikát *Research_group* více cílových skupin. Ve výsledku však bude transformován pouze jeden atribut rozkladové tabulky na predikát, jež bude reprezentovat vazbu mezi první z původních provázaných tabulek prostřednictvím konstrukce *rdfs:range* a druhou tabulkou prostřednictvím domény predikátu (*rdfs:domain*). Výraz *rdfs:range* přiřazený k vybranému predikátu umožňuje vyjádřit náležitost instance ke rodičovské třídě (definované hodnotou *rdfs:range*) pokud je tato instance objektem trojice se zmíněným predikátem. V rámci této transformace bude využito *rdfs:range* zároveň k vyjádření cílového objektu pro predikát, stejně jako bylo využito domény pro určení zdrojového subjektu daného

predikátu. Rozhodnutí která z vázaných tabulek určí predikátu hodnotu *rdfs:domain* či *rdfs:range* je odvislá od sémantického významu této vazby jež bude propojovat výsledné instance tříd a určí tak směr vazby (v případě reprezentace modelu orientovaným grafem se bude určovat směr šipky daného predikátu – viz predikát *Measure* na obrázku 5.1).

Pro názornost tohoto postupu bude uvedena ukázka transformace původní tabulky *COEXPERIMENTER_REL* nesoucí atributy *EXPERIMENT_ID* a *PERSON_ID*, tak jak ukazuje obrázek 7.2.



Obrázek 7.2: Znázornění transformace rozkladové tabulky

Tato tabulka umožňuje zaznamenat násobnou vazbu mezi záznamy tabulek *EXPERIMENT* a *PERSON* vyjadřující účast více výzkumníků podílejících se na provádění experimentu. Výsledkem aplikace výše uvedeného postupu bude vzniklý predikát jehož doména (*rdfs:domain*) bude mít hodnotu *Experiment* (třída) a *rdfs:range* hodnotu *Researcher*. Hodnotu URI tohoto predikátu lze zvolit např. *experiment/coexperiment_person*.

7.3.3 Transformace atributů tabulek

Transformace atributů tabulek již byla popsána v předchozích odstavcích, ze kterých je zřejmý postup vzniku výsledného predikátu. K již uvedenému

postupu určení domény predikátu dle tabulky původního modelu je nutné ještě uvést postup určení rozsahu (*rdfs:range*) cílových objektů predikátem vázaných trojic. V případě atributů rozkladových tabulek je tento cílový rozsah určen právě jedním z těchto atributů. Rozsah (*rdfs:range*) transformovaného atributu u nerozkladové tabulky je určen doménou (ve smyslu relační databáze) tohoto atributu. Pokud je tato (relační) doména původního atributu určena cizím klíčem jiné tabulky s níž má atribut zajistit provázání, pak tato cílová tabulka (transformovaná na třídu) určuje i rozsah predikátu. V opačném případě kdy relační doména je určena pouze datovým typem omezujícím přípustné hodnoty atributu bude rozsah určen rovněž datovým typem, který ale bude definován prostřednictvím XSD datových typů. Určení toho typu je dáno tabulkou XX uvedenou v následující podkapitole.

7.3.4 Transformace datových typů

Pro určení datových typů rozsahů (*rdfs:range*) predikátů a literálů transformovaných z hodnot atributů záznamů tabulek slouží následující tabulka 7.2. Ta popisuje transformaci datových typů relační databáze na základní datové typy sémantického webu definované XSD schématem.

Relační databáze	Sémantický web
<i>VARCHAR2</i>	<i>xsd:string</i>
<i>CHAR</i>	<i>xsd:string</i>
<i>NUMBER</i>	<i>xsd:integer</i>
<i>LONG</i>	<i>xsd:long</i>
<i>FLOAT</i>	<i>xsd:float</i>
<i>DATE</i>	<i>xsd:date</i>
<i>TIMESTAMP</i>	<i>xsd:dateTime</i>

Tabulka 7.2: Transformace datových typů relační databáze


Názvy datových typů relační databáze vycházejí z názvů užívaných portálovou databází Oracle.

7.3.5 Transformace záznamů tabulek

Záznamy tabulek původního modelu se transformují na instance tříd (*rdf:type*) vzniklých z těchto tabulek. Pro každý záznam se tak vytvoří nové URI jež bude sloužit k jeho identifikaci a především jako subjekt trojic přiřazujících této instanci prostřednictvím vytvořených predikátů hodnoty objektů. Hodnoty těchto objektů závisí na hodnotě atributu původního záznamu. Bude-li původní hodnota atributu cizím klíčem jiné tabulky pak přiřazovaným objektem bude instance třídy vzniklá ze záznamu určeného tímto cizím klíčem. V opačném případě bude na základě původní hodnoty atributu vytvořen nový literál nesoucí tuto hodnotu, jehož datový typ bude odpovídat transformovanému datovému typu (dle tabulky 7.2) původní domény atributu (původní datový typ atributu).

7.3.6 Dodání sémantiky modelu

Nově vytvořenému modelu bude dodána sémantika prostřednictvím hierarchického uspořádání všech transformací získaných tříd a predikátů ke kterým budou navíc dodány popisné informace. Hierarchického uspořádání je možné dosáhnout využitím konstrukcí *rdfs:subClassOf* a *rdfs:subPropertyOf*. Z původního relačního modelu tvořeného množinou rovnocenných tabulek tak vzniká objektový model, který bude mít částečně stromovou strukturu. Jednoduchým způsobem je tedy dosaženo například oddělení zaznamenávaných osob jež provádějí experimenty od těch co jsou měřeným subjektem, tak jak znázorňuje obrázek 7.3.



Obrázek 7.3: Znázornění dodání sémantiky modelu

Ve výsledném modelu byla dále vytvořena rodičovská třída pro všechny třídy uchovávající údaje o měřících elektrodách či pro metadata popisující scénář měření. Kompletní navržená struktura tříd modelu v XML zápisu ke zobrazení v příloze XX. Význam tohoto zápisu je popsán v následující podkapitole Implementace transformace modelu.

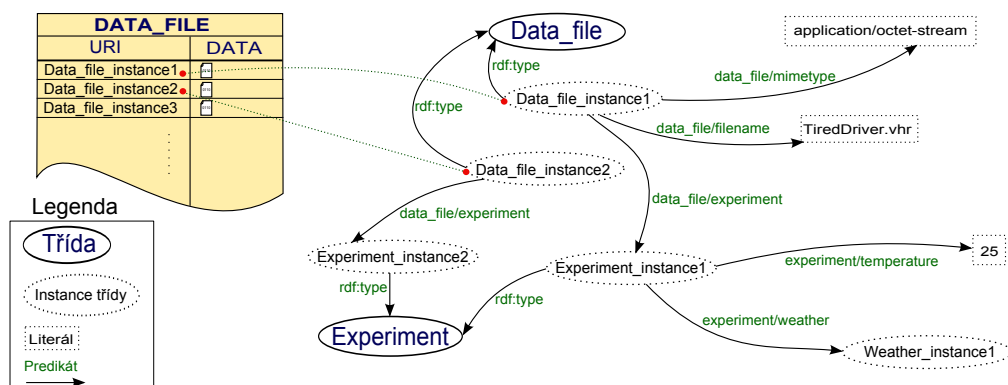
Každé vytvořené třídě a predikátu (property) je navíc dodávána prostřednictvím konstrukce *rdfs:comment* popisná informace (viz obrázek 7.3) umožňující uživateli získat představu o významu daných struktur modelu, které jsou jinak popsány pouze prostřednictvím URI (byť se sebelépe zvolenou hodnotou). V důsledku tak získáváme do určité míry samopopisný datový model.

7.3.7 Řešení rozšiřujících tabulek

Původní relační model obsahuje několik tabulek nesoucích ve svém názvu řetězec *PARAM_DEF* a *PARAM_VAL* jež slouží k uložení dalších rozšiřujících hodnot tabulek ke kterým jsou vázané. Do popisované transformace nebudou tyto tabulky zahrnuty neboť by obsahem svých záznamů porušovaly návrh výsledného modelu. Funkce kterou tyto tabulky v původnímu modelu plní pouze pro vázané tabulky ale poskytuje výsledný transformovaný model všem uloženým datům, díky své koncepci. Toho je dosaženo prostřednictvím možnosti vytváření nových predikátů (property) modelu, které umožňují dodávat další nová metadata libovolným subjektům aniž by došlo k porušení původní struktury modelu. V případě požadavku vícenásobného využití nově definovaných metadat a jejich hodnot je rovněž možné rozšířit model o další třídy a její instance čímž lze dále jednoduše dynamicky datový model rozšiřovat. Názornou ukázkou ověřující toto tvrzení je testovací aplikace popisovaná v následující kapitole testování.

7.3.8 Ukázka transformace

Níže uvedený obrázek 7.4 graficky znázorňuje výsledek provedené transformace dle popisovaných pravidel. Vzhledem k velikosti datového modelu je zde zobrazena pouze jeho část, přičemž celý model zapsaný prostřednictvím XML souboru je uložen na příloženém CD.



Obrázek 7.4: Znázornění částí výsledného modelu

7.3.9 Výhody navrženého modelu

7.3.10 Nevýhody navrženého modelu

8 Testování řešení

9 Závěr

Seznam zkratek a pojmů

API Application Programming Interface, rozhraní pro programování aplikací

AWT Abstract Window Toolkit, knihovna Javy pro tvorbu grafického uživatelského rozhraní

EEG Electroencephalography, metoda vyšetření elektrické aktivity centrálního nervového systému

ERP Event Related Potential, vyšetření reakcí mozku na vnější podněty

OWL Web Ontology Language, ontologický jazyk sémantického webu

RDF Resource Description Framework, metodika modelování informací v sémantickém webu

SPARQL SPARQL Protocol and RDF Query Language, dotazovací jazyk nad RDF grafy

URI Uniform Resource Identifier, jednotný identifikátor zdroje informací

W3C World Wide Web Consortium, organizace vyvíjející webové standardy

XML Extensible Markup Language, značkovací jazyk vyvinutý W3C

XSD XML Schema Definition, XML schéma popisující strukturu XML dokumentu

URI

Graf

Orientovaný graf

XSLT

MVC

JSP

API

Seznam obrázků

2.1	Architektura sémantickém webu [27]	5
2.2	Příklad RDF trojice	6
2.3	Příklad jednoduchého RDF modelu	7
2.4	Vztahy mezi vlastnosmi a třídami RDFS	10
3.1	Architektura MVC	17
4.1	Znázornění relace	20
5.1	Znázornění hierarchické organizace dat	27
7.1	ERA model relační části transformovaného modelu	34
7.2	Znázornění transformace rozkladové tabulky	37
7.3	Znázornění dodání sémantiky modelu	39
7.4	Znázornění částí výsledného modelu	41

Literatura

- [1] *Jena – A Semantic Web Framework for Java*, 2010.
<http://jena.apache.org>, (přístup 15.4.2013).
- [2] *Semantic Web Tools*, <http://semanticweb.org/wiki/Tools>, (přístup 19.2.2013).
- [3] Gilfillan Ian. *Introduction to Relational Databases*,
<http://www.databasejournal.com/sqletc/article.php/1469521/Introduction-to-Relational-Databases>, (přístup 16.2.2013).
- [4] Kauler Jan. *Základní pojmy databáze*. České vysoké učení technické v Praze, webzam.fbmi.cvut.cz/szabozol/ISZ/Kauler/506.doc, (přístup 17.2.2013).
- [5] Kauler Jan. *Relační datový model*. České vysoké učení technické v Praze, webzam.fbmi.cvut.cz/szabozol/ISZ/Kauler/508.doc, (přístup 17.2.2013).
- [6] Kolena Jan. *EEG/ERP portal - reservation system for EEG/ERP laboratory*. ZČU, Plzeň, 2011.
- [7] Zendulka Jaroslav. *Relační model dat*. Vysoké učení technické v Brně, http://www.fit.vutbr.cz/study/courses/DSI/public/pdf/nove/4_2.pdf, (přístup 5.2.2013).
- [8] JBoss Community. *Hibernate*, 2010. <http://www.hibernate.org/>, (přístup 6.1.2011).
- [9] Kosek Jiří. *Jak pracují databáze na Webu*,
<http://www.kosek.cz/clanky/iweb/12.html>, (přístup 15.2.2013).
- [10] Pitner Tomáš Matulík Petr. *Sémantický web a jeho technologie*. Masarykova univerzita, 2004. <http://www.ics.muni.cz/zpravodaj/articles/296.html>, (přístup 6.2.2013).

- [11] Openlink Software. *Virtuoso Universal Server*, <http://virtuoso.openlinksw.com/>, (přístup 19.2.2013).
- [12] Oracle. *Oracle Database Semantic Technologies Tutorial*, http://download.oracle.com/otndocs/tech/semantic_web/pdf/oradb_semtech_tutorial.pdf, (přístup 19.2.2013).
- [13] Oracle. *Oracle Spatial*, http://www.orafaq.com/wiki/Spatial_FAQ, (přístup 19.2.2013).
- [14] Brůha Petr. *EEG/ERP portál a prostředky sémantického webu*. ZČU, Plzeň, 2011.
- [15] Hanyáš Petr. *Sémantický web - tutoriál a demonstrační příklady*. Vysoké učení technické v Brně, 2007. http://www.hanyas.net/download/soubor:bp_cesky.pdf, (přístup 6.1.2013).
- [16] Semantic web. *Ontology*, 2012. <http://semanticweb.org/wiki/Ontology>, (přístup 9.2.2013).
- [17] Svátek Vojtěch. *Sémantický web*, 2010. <http://nb.vse.cz/svatek/rzzw/seweb-prehled.pdf>, (přístup 10.2.2013).
- [18] Svátek Vojtěch. *SPARQL*, 2010. <http://nb.vse.cz/svatek/rzzw/SPARQL> 11.2.2013).
- [19] Zánlostní technologie. *Univerzita Hradec Králové*, 2006. http://lide.uhk.cz/fim/ucitel/fshusam2/lekarnicky/zt1/zt1_kap02.html, (přístup 9.2.2013).
- [20] Štencek Jiří. *Užití sémantických technologií ve značkovacích jazycích*. Vysoká škola ekonomická v Praze, 2009. <http://vse.stencek.com/semanticky-web/>, (přístup 4.2.2013).
- [21] Vitvar Tomáš. *Sémantický web*. ČVUT, Praha, 2011, <http://www.cvut.cz/pracoviste/odbor-rozvoje/stranky/habilitace-a-inaugurace/habilitacni-p>
- [22] Homola Vladimír. *Kartézský součin, relace*. Vysoká škola báňská, <http://homel.vsb.cz/hom50/SLBSTATS/MNO/GS01B.HTM>, (přístup 17.2.2013).
- [23] W3C. *RDF Concepts and Abstract Syntax*, 2004. <http://www.w3.org/TR/2004/REC-rdf-concepts-20040210/>, (přístup 7.2.2013).

-
- [24] W3C. *OWL Web Ontology Language Overview*, 2004.
<http://www.w3.org/TR/owl-features/>, (přístup 10.2.2013).
 - [25] W3C. *RDF/XML Syntax Specification*, 2004.
<http://www.w3.org/TR/REC-rdf-syntax>, (přístup 6.2.2013).
 - [26] W3C. *RDF Vocabulary Description Language 1.0*, 2004.
<http://www.w3.org/TR/rdf-schema/>, (přístup 8.2.2013).
 - [27] W3C. *W3C Semantic Web Activity*, 2006.
<http://www.w3.org/2001/12/semweb-fin/w3csw>, (přístup 8.1.2013).
 - [28] W3C. *SPARQL Query Language for RDF*, 2008.
<http://www.w3.org/TR/rdf-sparql-query>, (přístup 8.2.2013).
 - [29] W3C. *XML Schema Part 2*, <http://www.w3.org/TR/xmlschema-2/>,
(přístup 20.2.2013).

Přílohy

A ERA model databáze EEG/ERP portálu

Priloha A - ERA model portalu